向量检索与 RAG 链路：从切片到召回

检索增强生成（RAG）把「检索」与「生成」解耦，先从一个外部知识库中检索与问题最相关的片段，再把片段
RAG
链路包含五个环节：创建知识库、导入并解析文档、对解析结果做切片、把切片向量化并建立索引、执行检索并
切片是决定检索质量最直接的环节。切片过大，召回的上下文会携带大量噪声；切片过小，单个片段语义不完整
token 数切分文本，并保留相邻片段之间的重叠，避免关键句子被切断；结构化切分则利用
Markdown 或 HTML
的标题层级，使每个片段落在语义边界上。二者没有绝对优劣，需要结合文档类型与下游模型上下文窗口来选择

向量化与召回

切片完成后，需要把文本转换为向量。典型做法是调用 embedding
模型，把每个切片映射为一个固定维度的向量，再写入支持向量检索的数据库。召回时，将用户问题用同一个模
Top-K
个最相似的切片，最后把这些切片拼接为上下文交给生成模型。相似度度量通常采用余弦相似度：它衡量两个向

一致性与验收

RAG 系统的核心是「切片、向量化、召回」三步。样本数据应当覆盖纯文本、Markdown、PDF 和 Word
等格式，才能充分验证解析与切片在不同输入下的行为一致性。除功能正确性之外，还应关注跨环节的一致性：